

Laboratorio 1

Anna Carelli (1029621) e Ilaria Consoli (944548)

Introduzione

Il laboratorio si sviluppa sulla creazione e analisi di definizioni di 4 concetti:

- Tree: concreto e generico
- Teapot: concreto e specifico
- Music: astratto e generico
- Ethics: astratto e specifico

Definizione dei concetti

Oltre alle definizioni già presenti nel dataset fornito, abbiamo aggiunto quelle scritte da noi di seguito:

Tree:

- a large-sized plant composed of a massive trunk, firmly anchored to the ground by underground branches called roots; Limbs extend from the upper part of the trunk, from which leaves grow. These enable the photosynthesis process. They can differ based on species, geographical area and climate. For example we have oak, cherry and pines. A group of them is generally called wood or forest.

Teapot:

- kitchen utensil used to heat beverages, particularly designed for preparing tea. It is a container with a variable shape and an opening at the top where the liquid, typically water, is poured; it has a handle to ensure a secure grip on one side and a tubular extension on the other side for pouring the beverage.

Music:

- Artistic discipline consisting of the rhythmic combination of sounds that can be defined as a composition. This is generally produced by artists using instruments and can be read and written graphically with notes on sheet music. It is divided into multiple genres and currents based on geographical origin and social context.

Ethics:

- Philosophical field that discusses the criteria determining whether a behavior is right or wrong. It is what regulates individuals' conduct and differs based on various domains, such as politics, religion, or social context. For example, abortion is the subject of constant debate between pro-life and pro-choice.

Analisi collettiva

Per descrivere i concetti sopracitati si è cercato di combinare diverse strategie definitorie; Fondamentalmente è stato usato il genus-differentia per ciascuna definizione fornendo una categoria generale per poi specificare le caratteristiche distintive come proprietà fisiche, funzionali e concettuali. Si sono poi unite altre strategie per dare più contesto alle definizioni; Sono stati inseriti esempi e riferimenti per richiamare casi già noti e rendere la definizione più familiare.

Le definizioni sono state scritte utilizzando un lessico specifico ma chiaro e leggibile. Si è cercato di spiegare i concetti minimizzando la complessità. Gli esempi fanno riferimento alla conoscenza comune, così da essere facilmente immaginabili. Per evitare la ricorsività, si è scelto di non utilizzare la parola da definire all'interno della sua stessa definizione.

L'obiettivo è stato di generalizzare in modo da rappresentare un'idea globale del concetto. Per le definizioni concrete, è stata data una descrizione strutturale senza scendere nei dettagli dei componenti. Invece in quelle astratte, è indicato il dominio a cui appartengono per poi dare un'immagine tangibile del concetto.

La difficoltà nel descrivere i concetti astratti rispetto ai concreti è l'assenza di una rappresentazione mentale.

Nel caso in cui si descrivono concetti che richiamano qualcosa di tangibile, è più facile dare una rappresentazione nota, perché mentalmente ne si visualizza forma e funzionamento.

Nel caso opposto non è immediato rendere una definizione evocativa. In questo caso, se il concetto lo permette, è opportuno scomporlo in frammenti di facile rappresentazione, come nel caso della musica con lo spartito e le note. Sempre per questa ragione, gli esempi sono risultati molto utili.

Confronto lessicale e semantico

Calcoliamo ora il grado di sovrapposizione semantico e lessicale delle definizioni, utilizzando il dataset contenente le altre definizioni analoghe.

Prima dell'analisi il dataset è stato ripulito di errori grammaticali e casi incongruenti, e infine tradotto in inglese nei casi di definizione in italiano.

Lo svolgimento consiste nel calcolare l'indice per tutte le combinazioni di due frasi dello stesso concetto per poi riportare il valore medio ottenuto.

Sovrapposizione lessicale

Prima del calcolo, è stato fatto un lavoro di pre-processing per eliminare le stop-words, normalizzare e lemmatizzare le definizioni. Per fare ciò utilizziamo la libreria *nltk*. Di seguito, la funzione:

Python

```
def clean_up(entry):
    lemmatizer = WordNetLemmatizer()
    stop_words = set(stopwords.words('english'))
    result = []
    for string in entry:
        words = nltk.word_tokenize(string.lower())
        filtered = [lemmatizer.lemmatize(word) for word in words if
word.isalpha() and word not in stop_words]
        result.append(" ".join(filtered))
    return result
```

L'indice di calcolo per la sovrapposizione lessicale che utilizziamo sarà la Jaccard Similarity [\(1\)](#). Il codice che abbiamo utilizzato su python per Jaccard è il seguente:

Python

```
def jaccard(def1, def2):
    words1 = set(def1.lower().split())
    words2 = set(def2.lower().split())

    intersection = words1.intersection(words2)
    union = words1.union(words2)

    jaccard_score = len(intersection) / len(union) if union else 0
    return jaccard_score

def jaccard_column(column):
    values = []
    for i in range(len(column)):
        for j in range(i+1, len(column)):
            values.append(jaccard(column[i], column[j]))
```

```
return np.mean(values)
```

Nella funzione *jaccard_column* i due cicli for sono fatti in modo che si eviti il confronto ridondante A-B B-A e A-A.

I risultati ottenuti sono:

- Tree: 0.18
- Teapot: 0.15
- Music: 0.09
- Ethic: 0.07

Dato che l'indice ha un range tra 0 e 1, si evince che il lessico utilizzato nel dataset è raramente ricorrente. Quindi si utilizzano parole diverse nonostante il significato comune.

Sovrapposizione semantica

Per vedere la similarità semantica delle nostre definizioni, utilizziamo il modello contestuale Sentence-BERT [\(2\)](#) per ottenere un embedding dell'intera frase e confrontarlo calcolando la cosine similarity.

Per fare tutto ciò basta importare la libreria *sentence_transformers*. Di seguito il codice:

```
Python
from sentence_transformers import SentenceTransformer, util
model = SentenceTransformer('all-MiniLM-L6-v2')

# Metodo per calcolare gli embedding
model.encode(sentences)

# Funzione per cosine similarity
def cosine_similarity(column):
    values = []
    for i in range(len(column)):
        for j in range(i+1, len(column)):
            sim = util.cos_sim(column[i], column[j])
            values.append(sim.item())
    return np.mean(values)
```

Anche per la funzione *cosine_similarity* si utilizza la stessa logica di *jaccard_column* per evitare ridondanze.

Così ci risultano i valori:

- Tree: 0.56
- Teapot: 0.61
- Music: 0.54
- Ethic: 0.50

Sempre considerando il range dell'indice da 0 a 1, emergono valori più elevati dato che si è valutata solo la similarità di significato.

Aggregazione dei risultati

Astratto e Concreto

In questo caso aggregiamo Music con Ethic e Tree con Teapot:

- Similarità Lessicale
 - Astratto: 0.08
 - Concreto: 0.17
- Similarità Semantica
 - Astratto: 0.52
 - Concreto: 0.59

Generico e Specifico

In questo caso aggregiamo Music con Tree e Ethic con Teapot:

- Similarità Lessicale
 - Generico: 0.14
 - Specifico: 0.11
- Similarità Semantica
 - Generico: 0.55
 - Specifico: 0.56

Riflessioni

Per quanto riguarda la sovrapposizione lessicale, ci aspettavamo dei valori più alti considerando la semplicità del linguaggio con cui si descrive il nucleo del concetto. Diversamente, per la sovrapposizione semantica, i risultati rispecchiano le nostre previsioni considerando che tutte le definizioni richiamano i significati previsti.

Il confronto evidenzia come i concetti fisici mostrino una sovrapposizione lessicale doppia rispetto agli astratti, perché ancorati a proprietà visibili e oggettive. Al contrario, l'astrazione ci porta ad esprimerci con maggiore soggettività, pur mantenendo un'accezione comune. Dunque la concretezza standardizza il linguaggio, mentre l'astrazione lo diversifica senza comprometterne il significato.

Se invece pensiamo a generico e specifico, emerge un paradosso nella sovrapposizione lessicale: risulta superiore per i termini generici piuttosto che per gli specifici. Potremmo ipotizzare che per i primi si faccia riferimento a un immaginario comune e a definizioni quasi preimpostate. Diversamente, quando passiamo allo specifico, i soggetti tendono a focalizzarsi su dettagli diversi, riducendo il numero delle parole coincidenti. Complessivamente, le due categorie rimangono coerenti dal punto di vista semantico.

La definizione più prototipica è Tree perché è rappresentata dal punto di vista botanico standard: una pianta che ha un fusto con rami e foglie. Anche Teapot segue la stessa logica: viene rappresentato come un contenitore per la preparazione del tè.

Per quanto riguarda Music e Ethic, riflettono sullo stesso tema partendo da punti di vista differenti: non si ha un prototipo unanime ma un'interpretazione personale.

Bibliografia

1. [Jaccard Similarity Made Simple: A Beginner's Guide to Data Comparison - Medium](#)
2. [Documentazione Sentence Transformer \(S-BERT\)](#)